

COMPARACIÓN DE ÁRBOLES DE DECISIÓN EN EL PROGRAMA WEKA


Se comparó los resultados del árbol de decisión de J48 en el programa Weka, aplicado al dataset ‘diabetes’ en dos escenarios: con los datos originales, sin ningún tratamiento, y con los datos preprocesados, donde se eliminaron los valores 0 inválidos en los atributos ‘plas’, ‘pres’, ‘skin’, ‘insu’ y ‘mass’.

Comparación de los árboles de decisión


Se identificó que las variables más relevantes para predecir la diabetes son 'plas' (glucosa), seguido de 'mass' (masa corporal).

La diferencia principal está en el tamaño y la profundidad del árbol: el árbol construido con los datos preprocesados es más grande y usa más atributos (incorpora skin, insu y pres en niveles más profundos), mientras que el árbol de los datos sin procesar es más compacto. Esto ocurre al no haber ceros inválidos, el modelo J48 encuentra nuevas divisiones útiles en esos atributos antes ignorados.

Árbol con datos sin procesar



Árbol con datos preprocesados



Resultados generales

La siguiente tabla resume los principales indicadores obtenidos en Weka para ambos modelos, evaluados sobre el mismo conjunto de prueba:

Summary	Sin procesar	Preprocesado
Correctly Classified Instances	117 (75.974 %)	118 (76.6234 %)
Incorrectly Classified Instances	37 (24.026 %)	36 (23.3766 %)
Kappa statistic	0.4493	0.443
Mean absolute error	0.3022	0.2919
Root mean squared error	0.430	0.4127
Relative absolute error	67.456 %	65.1461 %
Root relative squared error	92.006 %	88.2991 %

En ambos casos el porcentaje de acierto(Correctly Classified Instances) es similar, pero el modelo con datos preprocesados logra una ligera mejora: clasifica correctamente una instancia más y reduce el error absoluto medio y el error cuadrático medio, lo que indica predicciones un poco más precisas y consistentes.

Matriz de confusión

La matriz de confusión muestra cómo se distribuyen los aciertos y errores entre las dos clases (negativo = no tiene diabetes, positivo = sí tiene diabetes):

	Sin procesar		Preprocesado	
	Pred. negativo	Pred. positivo	Pred. negativo	Pred. positivo
Real negativo	86	19	90	15
Real positivo	18	31	21	28

Con los datos preprocesados, el modelo identifica mejor a las pacientes sanas con 90 aciertos frente a 86, pero reduce ligeramente su capacidad para detectar a las pacientes con diabetes con 28 aciertos frente a 31. Esto se debe a que, al quedar varios valores marcados como faltantes, el árbol cuenta con menos información (ceros que eran inválidos), pero también con menos datos completos para algunos casos positivos.

Conclusión

El preprocesamiento del dataset mejora ligeramente la exactitud general del modelo y reduce el error de predicción, además de generar un árbol de decisión más completo que aprovecha más atributos. Sin embargo, esta mejora es pequeña y viene acompañada de una leve baja en la detección de casos positivos de diabetes. En fin, el modelo con datos preprocesados es más confiable, porque sus decisiones se basan en información real y no en valores 0 que representaban mediciones inválidas.